

Exercice 1 :

Dans un supermarché, on dispose de la base de transactions suivante :

a1 dans tous les paniers (p1 à p12)
a2 dans paniers pairs (p2, p4, p6, p8, p10, p12)
a3 dans paniers multiples de 3 (p3, p6, p9, p12)
a4 dans paniers multiples de 4 (p4, p8, p12)
a5 dans paniers multiples de 5 (p5, p10)
a6 dans paniers multiples de 6 (p6, p12)

En utilisant l'algorithme Apriori avec un support minimum de 20% et une confiance minimale de 75%, trouver :

1. Les motifs fréquents,
2. Les motifs fréquents fermés,
3. Les motifs fréquents maximaux,
4. Les règles solides d'association de type $A, B \Rightarrow C$.

Étape 1 : Support des items simples (F1)

Calcul du support = nombre de paniers contenant l'article / 12

Article	Paniers concernés	Nombre	Support
a1	p1, p2, ..., p12 (tous)	12	12/12=1.0
a2	p2, p4, p6, p8, p10, p12	6	6/12=0.5
a3	p3, p6, p9, p12	4	4/12=0.333
a4	p4, p8, p12	3	3/12=0.25
a5	p5, p10	2	2/12=0.167 (inférieur à 0.2)
a6	p6, p12	2	2/12=0.167 (inférieur à 0.2)

Seuil support = 0.2 (20%), donc on garde uniquement les articles avec support ≥ 0.2 :

F1 = {a1, a2, a3, a4}

Étape 2 : Génération des candidats de taille 2 (C2) et calcul des supports

Liste des paires possibles (à partir de F1) :

- a1a2, a1a3, a1a4, a2a3, a2a4, a3a4

Calcul du support pour chaque :

Paire	Paniers contenant la paire	Nombre	Support
a1a2	Intersect(p1..p12, p2,p4,p6,p8,p10,p12) = p2,4,6,8,10,12	6	6/12=0.5
a1a3	p3,6,9,12	4	4/12=0.333
a1a4	p4,8,12	3	3/12=0.25
a2a3	intersection paires & multiples de 3 = p6,12	2	2/12=0.167 (inférieur à 0.2)
a2a4	intersection paires & multiples de 4 = p4,8,12	3	3/12=0.25
a3a4	intersection multiples de 3 & 4 = p12	1	1/12=0.083 (inférieur à 0.2)

Paire	Paniers contenant la paire	Nombre	Support
		0.2)	

On garde les paires avec support ≥ 0.2 :

F2 = {a1a2, a1a3, a1a4, a2a4}

Étape 3 : Génération des candidats de taille 3 (C3) et calcul des supports

Génération possible à partir de F2 :

- a1a2a4 (car a1a2 et a2a4 partagent a2)
- a1a3a4 ? Non car a3a4 non fréquent
- a1a2a3 ? Non car a2a3 non fréquent

Calcul support :

Triplet	Paniers contenant la triplet	Nombre	Support
a1a2a4	intersection de a1a2 (p2,4,6,8,10,12) et a2a4 (p4,8,12) = p4,8,12	3	3/12=0.25

F3 = {a1a2a4}

Étape 4 : Génération candidats taille 4 (C4)

Seulement un candidat possible : a1a2a3a4 ? Non possible car a2a3 non fréquent.

Donc **F4 = $\emptyset$**

Résumé des motifs fréquents

- F1 = {a1, a2, a3, a4}
- F2 = {a1a2, a1a3, a1a4, a2a4}
- F3 = {a1a2a4}
- F4 = $\emptyset$

Étape 5 : Motifs fréquents fermés

Un motif est fermé s'il n'a pas de super-ensemble avec le même support.

- a1 (support 12) → a1a2 (6), a1a3 (4), a1a4 (3) → pas même support → a1 fermé
- a2 (6) → a1a2 (6) même support → a2 **non fermé**
- a3 (4) → a1a3 (4) même support → a3 **non fermé**
- a4 (3) → a1a4 (3), a2a4 (3) et a1a2a4 (3) → même support 3 → a4 **non fermé**
- a1a2 (6) → pas de super-ensemble avec support 6 → fermé
- a1a3 (4) → pas de super-ensemble avec support 4 → fermé
- a1a4 (3) → a1a2a4 (3) même support → non fermé
- a2a4 (3) → a1a2a4 (3) même support → non fermé

- $a1a2a4$ (3) $\rightarrow$ pas de super-ensemble $\rightarrow$ fermé

Motifs fermés = {a1, a1a2, a1a3, a1a2a4}

Étape 6 : Motifs fréquents maximaux

Motifs qui n'ont aucun super-ensemble fréquent.

- $a1a2a4$ (taille 3) $\rightarrow$ pas de super-ensemble fréquent $\rightarrow$ maximal
- $a1a3$ (taille 2) $\rightarrow$ pas de super-ensemble fréquent contenant $a1a3 \rightarrow$ maximal

Les autres sont sous-ensembles de ces motifs.

Motifs maximaux = {a1a3, a1a2a4}

Étape 7 : Règles solides (confiance $\geq 75\%$) de la forme $A, B \Rightarrow C$

On examine les motifs fréquents de taille ≥ 2 pour générer des règles.

Règles issues de $a1a2a4$

- $a1a2 \Rightarrow a4$
 - $\text{Support}(a1a2a4) = 3/12 = 0.25$
 - $\text{Support}(a1a2) = 6/12 = 0.5$
 - $\text{Confiance} = 0.25 / 0.5 = 0.5 = 50\% < 75\% \rightarrow$ rejetée
- $a1a4 \Rightarrow a2$
 - $\text{Support}(a1a2a4) = 0.25$
 - $\text{Support}(a1a4) = 3/12 = 0.25$
 - $\text{Confiance} = 0.25 / 0.25 = 1.0 = 100\% \geq 75\% \rightarrow$ acceptée
- $a2a4 \Rightarrow a1$
 - $\text{Support}(a1a2a4) = 0.25$
 - $\text{Support}(a2a4) = 3/12 = 0.25$
 - $\text{Confiance} = 0.25 / 0.25 = 1.0 = 100\% \geq 75\% \rightarrow$ acceptée
- $a1 \Rightarrow a2$
 - $\text{Support}(a1a2) = 0.5$
 - $\text{Support}(a1) = 1.0$
 - $\text{Confiance} = 0.5 / 1.0 = 50\% < 75\% \rightarrow$ rejetée
- $a1 \Rightarrow a4$
 - $\text{Support}(a1a4) = 0.25$

- $\text{Support}(a1) = 1.0$
- $\text{Confiance} = 0.25 / 1.0 = 25\% < 75\% \rightarrow \text{rejetée}$
- $a2 \Rightarrow a4$
 - $\text{Support}(a2a4) = 0.25$
 - $\text{Support}(a2) = 0.5$
 - $\text{Confiance} = 0.25 / 0.5 = 50\% < 75\% \rightarrow \text{rejetée}$

Règles issues de a1a3

- $a1 \Rightarrow a3$
 - $\text{Support}(a1a3) = 4/12 = 0.333$
 - $\text{Support}(a1) = 1.0$
 - $\text{Confiance} = 0.333 / 1.0 = 33.3\% < 75\% \rightarrow \text{rejetée}$
- $a3 \Rightarrow a1$
 - $\text{Support}(a1a3) = 0.333$
 - $\text{Support}(a3) = 0.333$
 - $\text{Confiance} = 0.333 / 0.333 = 100\% \geq 75\% \rightarrow \text{acceptée}$

Récapitulatif des règles solides

- $(a1a4) \Rightarrow a2$ (confiance 100%)
- $(a2a4) \Rightarrow a1$ (confiance 100%)
- $(a3) \Rightarrow a1$ (confiance 100%)

Exercice 2 :

Exercice

On considère la base de transactions suivante (8 transactions) avec les articles A, B, C, D, E :

Transaction Articles achetés

T1	A, B, C
T2	A, B
T3	A, C
T4	B, C, D
T5	A, B, C, D
T6	B, D

Transaction Articles achetés

T7	A, B, C
T8	A, B, D

Objectif

Avec un **support minimum = 50%** (au moins 4 transactions) et une **confiance minimum = 70%**, trouvez :

1. Les motifs fréquents,
 2. Les motifs fréquents fermés,
 3. Les motifs fréquents maximaux,
 4. Les règles d'association solides de la forme $A, B \Rightarrow C$.
-

Solution

Étape 1 : Calcul des supports pour les items simples (taille 1)

Article Transactions contenant l'article Support (fréquence / 8)

A	T1, T2, T3, T5, T7, T8	6
B	T1, T2, T4, T5, T6, T7, T8	7
C	T1, T3, T4, T5, T7	5
D	T4, T5, T6, T8	4
E	— none —	0

Support min = 50%, donc on garde :

F1 = {A, B, C, D}

Étape 2 : Génération des candidats taille 2 (C2) et calcul des supports

Liste des paires formées à partir de F1 :

- AB, AC, AD, BC, BD, CD

Calcul du support :

Paire Transactions contenant la paire Support

AB	T1, T2, T5, T7, T8	$5/8 = 62.5\%$
AC	T1, T3, T5, T7	$4/8 = 50\%$
AD	T5, T8	$2/8 = 25\%$
BC	T1, T4, T5, T7	$4/8 = 50\%$

Paire Transactions contenant la paire Support

BD T4, T5, T6, T8 4/8 = 50%

CD T4, T5 2/8 = 25%

On garde celles avec support $\geq 50\%$:

F2 = {AB, AC, BC, BD}

Étape 3 : Génération des candidats taille 3 (C3) et calcul des supports

Les triplets possibles (à partir de F2) sont ceux dont toutes les paires sont fréquentes :

- ABC (car AB, AC, BC sont fréquents)
- ABD (car AB, BD fréquents, mais AD non fréquent → on élimine ABD)
- BCD (car BC, BD fréquents, mais CD non fréquent → on élimine BCD)
- ACD (AC fréquent, CD non fréquent → éliminé)

Donc seul ABC est candidat.

Calcul support ABC :

- Transactions contenant A, B, C : T1, T5, T7
- Support = 3/8 = 37.5% < 50% → rejeté

Donc **F3 = $\emptyset$**

Étape 4 : Résumé des motifs fréquents

Taille Motifs fréquents

- 1 A, B, C, D
 - 2 AB, AC, BC, BD
 - 3 $\emptyset$
-

Étape 5 : Motifs fréquents fermés

Un motif est fermé s'il n'a pas de super-ensemble avec le même support.

- A (6) → AB (5), AC (4) → pas même support → A fermé
- B (7) → AB (5), BC (4), BD (4) → pas même support → B fermé
- C (5) → AC (4), BC (4) → pas même support → C fermé
- D (4) → BD (4) même support → D non fermé

- AB (5) → pas de super-ensemble fréquent → fermé
- AC (4) → pas de super-ensemble fréquent → fermé
- BC (4) → pas de super-ensemble fréquent → fermé
- BD (4) → pas de super-ensemble fréquent → fermé

Étape 6 : Motifs fréquents maximaux

Motifs fréquents sans super-ensemble fréquent :

- AB (5), AC (4), BC (4), BD (4)
Aucun triplet fréquent → tous ces couples sont maximaux.

Étape 7 : Règles d'association solides (confiance $\geq 70\%$)

Règles à partir de AB (support 62.5%)

- $A \Rightarrow B$: confiance = support(AB)/support(A) = $5/6 \approx 83.3\% \geq 70\% \rightarrow$ valide
- $B \Rightarrow A$: confiance = $5/7 \approx 71.4\% \geq 70\% \rightarrow$ valide

Règles à partir de AC (support 50%)

- $A \Rightarrow C$: $4/6 \approx 66.7\% < 70\% \rightarrow$ rejetée
- $C \Rightarrow A$: $4/5 = 80\% \geq 70\% \rightarrow$ valide

Règles à partir de BC (support 50%)

- $B \Rightarrow C$: $4/7 \approx 57.1\% < 70\% \rightarrow$ rejetée
- $C \Rightarrow B$: $4/5 = 80\% \geq 70\% \rightarrow$ valide


Règles à partir de BD (support 50%)

- $B \Rightarrow D$: $4/7 \approx 57.1\% < 70\% \rightarrow$ rejetée
- $D \Rightarrow B$: $4/4 = 100\% \geq 70\% \rightarrow$ valide

Catégorie	Résultats
Motifs fréquents	A, B, C, D, AB, AC, BC, BD
Motifs fréquents fermés	A, B, C, AB, AC, BC, BD
Motifs maximaux	AB, AC, BC, BD
Règles solides	$A \Rightarrow B$ (83.3%), $B \Rightarrow A$ (71.4%), $C \Rightarrow A$ (80%), $C \Rightarrow B$ (80%), $D \Rightarrow B$ (100%)

Exercice 3 :

Soit le treillis suivant représentant les motifs obtenus à partir des items A,B,C et E avec leurs fréquences :



En supposant que la fréquence minimale est de 3 et que la confiance minimale est de 0.8, donner :

1. L'ensemble des motifs fréquents.
2. Les motifs fréquents fermés et les motifs fréquents maximaux.
3. Les motifs rares.
4. Les règles solides obtenues à partir du motif fréquent maximal le plus long.

1. Ensemble des motifs fréquents

Un motif est fréquent s'il a une fréquence (support) ≥ 3 .

D'après l'énoncé, les motifs fréquents sont :

{A;B;C;E;AC;BE;BC;CE;BCE}

2. Motifs fréquents fermés

Un motif fréquent est **fermé** s'il n'existe pas de super-ensemble avec le même support.

Motifs fermés donnés :

{C;E;AC;BCE}

Interprétation :

- C est fréquent et fermé (pas de super-ensemble avec même fréquence).

- E idem.
- AC est fermé.
- BCE est fermé.

Les autres motifs (A, B, BE, BC, CE) ne sont pas fermés car il existe des super-ensembles avec le même support.

3. Motifs fréquents maximaux

Un motif fréquent est **maximal** s'il n'a aucun super-ensemble fréquent.

Motifs maximaux donnés :

{AC;BCE}

Cela signifie que AC et BCE sont les plus grands motifs fréquents (pas de motifs plus grands qui soient fréquents).

4. Motifs rares

Motifs rares = motifs dont la fréquence est < 3 .

D'après l'énoncé, les motifs rares sont :

{AB;AE;ABC;ABE;ACE;ABCE}

5. Règles solides extraites du motif fréquent maximal le plus long

Le motif fréquent maximal le plus long est **BCE** (taille 3).

On génère des règles d'association de la forme $A, B \Rightarrow C$ à partir de BCE, avec confiance ≥ 0.8 .

Les règles solides données :

- (a) $BC \Rightarrow E$
 - (b) $BE \Rightarrow C$
 - (c) $CE \Rightarrow B$
-

Calculs de support et confiance

Soit $\text{support}(X)$ la fréquence de l'itemset X.

La confiance de la règle $X \Rightarrow Y$ est calculée par :

$\text{confiance} = \text{support}(X \cup Y) / \text{support}(X)$

Ici :

- $\text{support}(BCE) \geq 3$ (motif fréquent maximal)
- Pour $BC \Rightarrow E$,

$\text{confiance} = \text{support}(BCE) / \text{support}(BC) \geq 0.8$

- Pour $BE \Rightarrow C$,
confiance = $\text{support}(BCE) / \text{support}(BE) \geq 0.8$
 - Pour $CE \Rightarrow B$,
confiance = $\text{support}(BCE) / \text{support}(CE) \geq 0.8$
-

Résumé

Étape	Résultat
Motifs fréquents	{A, B, C, E, AC, BE, BC, CE, BCE}
Motifs fréquents fermés	{C, E, AC, BCE}
Motifs fréquents maximaux	{AC, BCE}
Motifs rares	{AB, AE, ABC, ABE, ACE, ABCE}
Règles solides (confiance ≥ 0.8)	$(BC \Rightarrow E)$, $(BE \Rightarrow C)$, $(CE \Rightarrow B)$

Exercice 4 :

On dispose de la base formelle suivante représentant les bilans des résultats d'analyse de 08 patients infectés par le corona virus COVID19 variant Delta et variant Omicron :

N R T F G O D
 1 1 1 0 0 1 1
 2 1 0 0 0 1 0
 3 0 0 1 0 0 1
 4 0 1 0 1 1 0
 5 1 1 0 0 1 1
 6 1 0 0 0 0 1
 7 0 1 0 1 1 0
 8 0 1 1 0 1 1

Où :

N: Numéro du patient,

R : Difficultés respiratoires,

T : Toux,

F : Fièvre,

G : Fatigue,

O : infecté par le variant Omicron,

D : Infecté par le variant Delta.

Sachant que le support minimum est de 30 % et la confiance est de 60 % :

1. Remplir le tableau suivant par Vrai pour spécifier le type de chaque motif ? (5 pts)

	Fréquent	Fermé	Fréquent Maximal	Rare

O				
D				
ODT				
R				
OR				
DR				
OT				
DT				
OD				
T				

- Donner la relation entre un motif fréquent, un motif fréquent fermé et un motif fréquent maximal.
- Trouver les motifs fréquents fermés et maximaux ?
- Ecrivez le pseudo qui permet d'obtenir des motifs rares ?
- Trouver les règles solides à partir des motifs fréquents de longueur 2 et plus ?
- Déduire un arbre de décision à partir de ces règles.
- Comparer les deux méthodes, motif fréquent et arbres de décision. Quels sont les avantages et les inconvénients de l'une par rapport à l'autre ?

Support des items simples

Item Transactions contenant l'item Support (nombre) Support (%) Est fréquent (≥ 3)

O	1, 2, 4, 5, 7, 8	6	75%	Oui
D	1, 3, 5, 6, 8	5	62.5%	Oui
R	1, 2, 5, 6	4	50%	Oui
T	1, 4, 5, 7, 8	5	62.5%	Oui
F	3, 8	2	25%	Non
G	4, 7	2	25%	Non

Support des motifs composés (longueur 2 et 3)

Calculons pour chaque motif demandé :

Motif	Transactions contenant le motif	Support (nombre)	Support (%)	Est fréquent (≥ 3)
OD	1, 5, 8	3	37.5%	Oui
ODT	1, 5, 8	3	37.5%	Oui
OR	1, 2, 5	3	37.5%	Oui
DR	1, 5, 6	3	37.5%	Oui
OT	1, 4, 5, 7, 8	5	62.5%	Oui
DT	1, 8	2	25%	Non
T	1, 4, 5, 7, 8	5	62.5%	Oui

1. Complétez le tableau des types de motifs

Motif	Fréquent	Fermé	Fréquent Maximal	Rare
O	Vrai	Vrai	Non	Faux
D	Vrai	Vrai	Non	Faux
ODT	Vrai	Vrai	Vrai	Faux
R	Vrai	Faux	Non	Faux
OR	Vrai	Faux	Non	Faux
DR	Vrai	Vrai	Vrai	Faux
OT	Vrai	Vrai	Vrai	Faux
DT	Faux	Non	Non	Vrai
OD	Vrai	Faux	Non	Faux
T	Vrai	Vrai	Non	Faux

Explications

- **Fréquent** : support ≥ 3
- **Fermé** : pas de super-ensemble avec même support (ex : ODT est fermé car aucun super-ensemble avec support 3)
- **Maximal** : pas de super-ensemble fréquent
- **Rare** : support < 3

2. Relation entre motif fréquent, fermé et maximal

- **Motif fréquent** : motif dont le support est supérieur ou égal au seuil.
- **Motif fermé** : motif fréquent qui n'a pas de super-ensemble avec le même support (informations non redondantes).
- **Motif maximal** : motif fréquent qui n'a pas de super-ensemble fréquent (motif fréquent le plus grand).

3. Motifs fréquents fermés et maximaux

- **Motifs fermés** : O, D, ODT, DR, OT, T
- **Motifs maximaux** : ODT, DR, OT

4. Pseudo-code pour obtenir les motifs rares

pseudo

```
Entrée : base de transactions, seuil_support_min

1. Générer tous les motifs fréquents avec support ≥
   seuil_support_min (par exemple avec Apriori)
2. Pour chaque motif possible (itemset) dans la base :
   Si motif n'est pas dans l'ensemble des motifs fréquents:
       Ajouter motif à l'ensemble des motifs rares
3. Retourner l'ensemble des motifs rares
```

5. Règles solides à partir des motifs fréquents de taille ≥ 2

Seuil confiance = 60%

Calcul des règles pour chaque motif fréquent (longueur ≥ 2)

Motif OT (support = 5)

- $O \Rightarrow T$: confiance = $\text{support}(OT)/\text{support}(O) = 5/6 \approx 83.3\% (\geq 60\%) \rightarrow$ valide
- $T \Rightarrow O$: confiance = $5/5 = 100\% \rightarrow$ valide

Motif ODT (support = 3)

- $OD \Rightarrow T$: $3/3 = 100\% \rightarrow$ valide
- $OT \Rightarrow D$: $3/5 = 60\% \rightarrow$ valide
- $DT \Rightarrow O$: $2/2 = 100\%$ mais DT n'est pas fréquent donc on ne considère pas cette règle.
- $O \Rightarrow DT$: $3/6 = 50\% < 60\% \rightarrow$ non valide

Motif DR (support = 3)

- $D \Rightarrow R$: $3/5 = 60\% \rightarrow$ valide
- $R \Rightarrow D$: $3/4 = 75\% \rightarrow$ valide

Motif OR (support = 3)

- $O \Rightarrow R : 3/6 = 50\% < 60\% \rightarrow$ non valide
- $R \Rightarrow O : 3/4 = 75\% \rightarrow$ valide

Motif OD (support = 3)

- $O \Rightarrow D : 3/6 = 50\% < 60\% \rightarrow$ non valide
- $D \Rightarrow O : 3/5 = 60\% \rightarrow$ valide

Récapitulatif des règles solides (confiance $\geq 60\%$)

Règle Confiance

$O \Rightarrow T$ 83.3%

$T \Rightarrow O$ 100%

$OD \Rightarrow T$ 100%

$OT \Rightarrow D$ 60%

$D \Rightarrow R$ 60%

$R \Rightarrow D$ 75%


$R \Rightarrow O$ 75%

$D \Rightarrow O$ 60%

6. Arbre de décision

On peut construire un arbre de décision pour prédire par exemple la présence du variant **O** (**Omicron**) à partir des symptômes R, T, D.

Exemple simple (basé sur règles solides):



- Si Toux (T) présente $\rightarrow$ O probable (car $T \Rightarrow O$ confiance 100%)
 - Sinon, si Difficultés respiratoires (R) présentes $\rightarrow$ O probable ($R \Rightarrow O$ confiance 75%)
 - Sinon, O absent ou incertain
-

7. Comparaison : Motifs fréquents vs Arbres de décision

Aspect	Motifs fréquents	Arbres de décision
Objectif	Identifier des motifs fréquents dans les données	Construire un modèle prédictif pour classification
Avantages	Découvre des relations intéressantes entre items (co-occurrences), facile à interpréter	Prédiction directe, gestion des variables continues et catégoriques
Inconvénients	Ne fournit pas directement un modèle prédictif, peut générer beaucoup de motifs	Peut être sensible au surapprentissage, moins intuitif que motifs pour certaines relations
Utilisation	Analyse exploratoire, recommandations, règles d'association	Classification, prise de décision, prédiction
Robustesse	Sensible au choix des seuils support/confiance	Robuste avec validation croisée et pruning
