

Série TD 3

Exercice 1 :

Construire un arbre de décision qui classifie par des conditions météorologiques si le joueur joue au tennis ou non :

Jour	Ciel	Température	Humidité	Vent	Jouer au tennis ?
1	Ensoleillé	Chaude	Élevée	Faible	Non
2	Ensoleillé	Chaude	Élevée	Fort	Non
3	Couvert	Chaude	Élevée	Faible	Oui
4	Pluie	Tiède	Élevée	Faible	Oui
5	Pluie	Fraiche	Normale	Faible	Oui
6	Pluie	Fraiche	Normale	Fort	Non
7	Couvert	Fraiche	Normale	Fort	Oui
8	Ensoleillé	Tiède	Élevée	Faible	Non
9	Ensoleillé	Fraiche	Normale	Faible	Oui
10	Pluie	Tiède	Normale	Faible	Oui
11	Ensoleillé	Tiède	Normale	Fort	Oui
12	Couvert	Tiède	Élevée	Fort	Oui
13	Couvert	Chaud	Normale	Faible	Oui
14	pluie	Tiède	Élevée	Fort	Non

Solution :

Avec un ensemble de jours (un jour = un exemple), chacun caractérisés par un numéro et ses conditions météorologiques (Température, Humidité, Vent, Ciel). Et un attribut cible "Jouer au tennis ?", dont les valeurs possibles sont Oui (représente l'exemple positif +) et Non (représente l'exemple négatif -).

Sur cet exemple on initialise avec un arbre vide. L'échantillon contient 14 éléments dont 9 ont pour classe oui (+) et 5 ont pour classe non (-). Pour déterminer la racine de l'arbre de décision de ceci avec l'algorithme ID3, on calcul les gains d'informations des attributs Ciel, Température, Humidité et vent.

- ✓ Tout d'abord, on commence par le gain d'information de l'attribut Ciel, on remarque que cet attribut peut prendre trois valeurs :
 - $X_{\text{Ciel}}=\text{Ensoleillé}$: ID3 est appelée récursivement avec 5 exemples.
 - $X_{\text{Ciel}}=\text{Couvert}$: ID3 est appelée récursivement avec 4 exemples.
 - $X_{\text{Ciel}}=\text{Pluie}$: ID3 est appelée récursivement avec 5 exemples.

$$\text{Alors : } \left\{ \begin{array}{l} 5 \text{ Ensoleillé : } [2 + 3-]. \\ 4 \text{ Couvert : } [4 + 0-]. \\ 5 \text{ Pluie : } [3 + 2-]. \end{array} \right.$$

Donc, en appliquant les formules précédentes, le gain d'information de l'attribut Ciel est :

$$\text{Gain}(X, \text{Ciel}) = E(X) - \frac{5}{14} E(X=\text{Ensoleillé}) - \frac{4}{14} E(X=\text{Couvert}) - \frac{5}{14} E(X=\text{Pluie}).$$

$$\text{Avec l'entropie initiale : } E(X) = -\frac{9}{14} \log_2 (9/14) - \frac{5}{14} \log_2 (5/14) = 0.940.$$

$$E(X=\text{Ensoleillé}) = -\frac{2}{5} \log_2 (2/5) - \frac{3}{5} \log_2 (3/5) = 0.971.$$

$$E(X=\text{Couvert}) = 0.$$

$$E(X=\text{Pluie}) = -\frac{3}{5} \log_2 (3/5) - \frac{2}{5} \log_2 (2/5) = 0.971.$$

$$\text{Donc : } \text{Gain}(X, \text{Ciel}) = 0.940 - \frac{5}{14} (0.971) - 0 - \frac{5}{14} (0.971) = 0.246.$$

$\text{Gain}(X, \text{Ciel}) = 0.246.$
--

On constate qu'à partir de notre jeu de données que l'attribut humidité peut prendre deux valeurs : soit $X_{\text{Humidité}} = \text{Normale}$, Soit $X_{\text{Humidité}} = \text{Élevée}$.

$$\text{Humidité } [9+;5-] = \begin{cases} 7 \text{ Élevée : } [3 + 4-]. \\ 7 \text{ Normale : } [6 + 1-]. \end{cases}$$

Alors le gain d'information pour cet attribut est calculé par :

$$\text{Gain}(X, \text{Humidité}) = E(X) - \frac{7}{14} E(X=\text{Normale}) - \frac{7}{14} E(X=\text{Élevée})$$

$$\text{Avec : } E(X) = -\frac{9}{14} \log_2 (9/14) - \frac{5}{14} \log_2 (5/14) = 0.940$$

$$E(X=\text{Normale}) = -\frac{6}{7} \log_2 (6/7) - \frac{1}{7} \log_2 (1/7) = 0.592$$

$$E(X=\text{Élevée}) = -\frac{3}{7} \log_2 (3/7) - \frac{2}{7} \log_2 (2/7) = 0.985.$$

Donc on obtient :

$\text{Gain}(X, \text{Humidité}) = 0.151.$
--

➤ Attribut Vent :

$$\text{Vent } [9+;5-] = \begin{cases} 8 \text{ Faible : } [6 + 2-] \\ 6 \text{ Fort : } [3 + 3-] \end{cases}$$

$$\text{Gain}(X, \text{Vent}) = E(X) - \frac{8}{14} E(X=\text{Faible}) - \frac{6}{14} E(X=\text{Fort}).$$

Donc En appliquant les mêmes démarches que les attributs ci-dessus on obtient:

$\text{Gain}(X, \text{Vent}) = 0.049.$
--

➤ Attribut Température :

$$\text{Température } [9+,5-] = \begin{cases} 4 \text{ Chaude} : [2 + 2-]. \\ 6 \text{ Tiède} : [4 + 2-]. \\ 4 \text{ Fraiche} : [3 + 2-]. \end{cases}$$

$$\text{Gain}(X, \text{Température}) = E(X) - 4/14 E(X=\text{Chaude}) - 6/14 E(X=\text{Tiède}) - 4/14 E(X=\text{Fraiche}).$$

$$\text{Gain}(X, \text{Température}) = 0.029.$$

$$\text{Racine de l'arbre de décision} = \max(0.246, 0.151, 0.048, 0.029) = 0.246.$$

Donc, la racine de l'arbre de décision est l'attribut " Ciel " et cet attribut sera éliminé du jeu de données.

✓ L'attribut Ciel peut prendre trois valeurs : Ensoleillé, Couvert et Pluie.

➤ On refait les calculs avec Ciel=Ensoleillé.

	Température	Humidité	Vent	Jouer
1	Chaude	Elevée	Faible	Non
2	Chaude	Elevée	Fort	Non
8	Tiède	Elevée	Faible	Non
9	Fraiche	Normale	Faible	Oui
11	Tiède	Normale	Fort	Oui

Pour "Ensoleillé" ID3 est appelé récursivement avec 5 exemples :(x1, x2, x8, x11). Les gains d'informations pour les 3 attributs restants sont alors calculé par :

$$\text{Humidité} = \begin{cases} 2 \text{ Normale} : [2 + 0-]. \\ 3 \text{ Elevé} : [0 + 3-]. \end{cases}$$

$$\text{Gain} (X_{\text{Ensoleillé}}, \text{Humidité}) = E(X_{\text{Ensoleillé}}) - 2/5 E (X_{\text{Ensoleillé}}=\text{Normale}) - 3/5 E (X_{\text{Ensoleillé}}=\text{Élevé}).$$

$$E_{\text{Ensoleillé}} = - 2/5 \log_2 (2/5) - 3/5 \log_2 (3/5) = 0.970.$$

$$E_{\text{Ensoleillé}} (X_{\text{Ensoleillé}}=\text{Élevée}) = - 3/5 \log_2 (3/5) = 0.$$


$$E_{\text{Ensoleillé}} (X_{\text{Ensoleillé}}=\text{Normale}) = - 2/5 \log_2 (2/5) = 0.$$

$$\text{Donc, Gain} (X_{\text{Ensoleillé}}, \text{Humidité}) = 0.970.$$


- En appliquant les mêmes formules pour les deux autres attributs on obtient :

Attribut	Gain d'information
Humidité	0.970
Vent	0.570
Température	0.019

L'attribut Humidité sera donc choisi pour les exemples dont l'attribut Ciel vaut Ensoleillé :



- ✓ On continue la construction de l'arbre de décision :
- Pour la branche Couvert de la racine Pluie, ID3 est appelé récursivement avec 4 exemples (x3, x7, x12, x13) où tous les exemples sont positives ainsi nous effectuons la classe "Oui" à cette feuille.
- Pour la branche Pluie comme ID3 est appelé récursivement avec 4 exemples (x4, x5, x6, x10, x14) donc on cherche le gain maximal entre les attributs.
- L'attribut Vent sera donc choisi. Alors avec l'algorithme ID3 nous avons finalement obtenu l'arbre de décision ci-dessous :



On constate que cet arbre de décision nous donne des informations sur la pertinence des attributs vis-à-vis de la classe. Ainsi, l'attribut "Température" n'étant pas utilisé dans l'arbre alors il n'est pas pertinent pour déterminer la classe. De surcroît, si l'attribut Ciel vaut "Pluie", l'attribut "Humidité" n'est pas pertinent. Si l'attribut "Ciel" vaut "Ensoleillé" alors c'est l'attribut "Vent" qui n'est pas pertinent.

Exercice 2 :

Dans un hôpital, on souhaite construire un arbre de décision pour la prédiction du risque des patients d'avoir une certaine maladie en fonction de leur âge et de deux symptômes booléens (vrai ou faux) appelés S1 et S2. Le risque est évalué selon trois valeurs F (faible), M (moyen) et E (élevé), l'âge est discrétisé selon trois classes (jeune, adulte et senior). L'hôpital dispose de la table suivante :


N°	Age	S1	S2	Risque	N°	Age	S1	S2	Risque
1	Jeune	F	V	F	6	Jeune	F	F	F
2	Jeune	V	V	E	7	Adulte	V	F	M
3	Adulte	F	F	F	8	Adulte	V	V	M
4	Senior	V	F	E	9	Senior	F	F	F
5	Senior	F	V	M	10	Senior	V	V	E

Questions :

1. Construire l'arbre souhaité en utilisant l'algorithme ID3.
2. Donner le risque du patient ayant les attributs (Jeune,V,F) selon l'arbre construit.

Solution :

1. L'arbre souhaité en utilisant l'algorithme ID3 :



2. Le risque du patient ayant les attributs (Jeune,V,F) selon l'arbre construit est E.

Exercice 3 :

Nous considérerons l'ensemble E d'exemples suivant ayant les attributs A,B,C et D :

	E_1	E_2	E_3	E_4	E_5	E_6	E_7	E_8	E_9	E_{10}
A	a_1	a_1	a_1	a_2	a_2	a_2	a_1	a_2	a_3	a_3
B	b_1	b_2	b_2	b_1	b_2	b_2	b_1	b_1	b_1	b_2
C	c_1	c_2	c_3	c_1	c_1	c_1	c_1	c_2	c_3	c_2
D	d_2	d_2	d_1	d_1	d_1	d_2	d_1	d_2	d_1	d_2
Classe	+	+	-	-	-	+	+	-	+	+

1. Construire l'arbre de décision correspondant à l'ensemble E en utilisant l'algorithme ID3.
2. Donner la précision de l'arbre obtenu sur la table d'entrainement. Calculer la moyenne harmonique sur la même table.


NB : On donne le tableau suivant représentant les valeurs de la fonctions

$$H(x, y) = -\frac{x}{x+y} \log_2\left(\frac{x}{x+y}\right) - \frac{y}{x+y} \log_2\left(\frac{y}{x+y}\right)$$

$x \backslash y$	1	2	3	4	5	6
6	0,592	0,811	0,918	0,971	0,994	1
5	0,650	0,863	0,954	0,991	1	
4	0,722	0,918	0,985	1		
3	0,811	0,971	1			
2	0,918	1				
1	1					

Solution :

- (a) Construire l'arbre de décision correspondant à l'ensemble E en utilisant l'algorithme ID3.



(b) La précision de l'arbre obtenu sur la table d'entraînement = 100 %

Moyenne harmonique $sv = \frac{6}{6} = 1$

$sp = \frac{4}{4} = 2$

Moyenne harmonique = $\frac{2 \times 1 \times 1}{1+1} = 1$

Exercice 4 :

Nous considérerons l'ensemble d'exemples représentant la nature de différents échantillons de champignons : toxique ou non selon les critères de couleur, taille, forme et le milieu de croissance:


Couleur	Taille	Forme	Milieu	Toxique
marron	petit	plat	terre	oui
jaune	petit	sphère	terre	oui
marron	moyen	conique	bois	non
blanc	moyen	sphère	terre	non
blanc	grand	plat	terre	non

1. Construire l'arbre de décision correspondant à cet ensemble en utilisant l'algorithme ID3.
2. Donner la précision de l'arbre et sa moyenne harmonique sur la table de test suivante :

Coleur	Taille	Forme	Milieu	Toxique
marron	grand	plat	bois	non
blanc	moyen	conique	terre	oui
jaune	moyen	sphère	terre	oui
marron	moyen	conique	bois	non
jaune	petit	plat	terre	oui

Solution :

1. Arbre construit par l'algorithme ID3



2. - Précision = $\frac{3}{5} = 60\%$

- Moyenne harmonique :

$$\begin{cases} Sv = \frac{CP}{CP+FN} = \frac{1}{1+2} = \frac{1}{3} \\ Sp = \frac{CN}{CN+FP} = \frac{2}{2+0} = 1 \end{cases}$$

$$\text{Moyenne harmonique} = \frac{2 \times Sv \times Sp}{Sv + Sp} = \frac{1/3 \times 1}{1/3 + 1} = 0.25$$

Exercice 5 :

1. Construire l'arbre de décision correspondant à cette base en utilisant l'algorithme ID3.


2. Donner la précision de l'arbre construit sur la base suivante :

client	M	A	R	E	I
01	moyen	âgé	village	oui	oui
02	élevé	jeune	ville	non	oui
03	faible	âgé	village	non	non
04	moyen	moyen	bourg	oui	non


Solution :

1. Construire l'arbre de décision correspondant à cette base en utilisant l'algorithme

ID3.



ou



2. Donner la précision de l'arbre :

Précision = $\frac{2}{4} = 50\%$

Exercice 6 :

On considère les données suivantes :

N°	Cheveux	Taille	Poids	Crème solaire	Classe
1	blond	moyenne	léger	non	coup de soleil
2	blond	grande	moyen	oui	bronzé
3	brun	petite	moyen	oui	bronzé
4	blond	petite	moyen	non	coup de soleil
5	roux	moyenne	lourd	non	coup de soleil
6	brun	grande	lourd	non	bronzé
7	brun	moyenne	lourd	non	bronzé
8	blond	petite	léger	oui	bronzé


1. Construire l'arbre de décision correspondant à cette base en utilisant l'algorithme ID3.

2. Donner la précision de l'arbre construit sur la base suivante :

N°	Cheveux	Taille	Poids	Crème solaire	Classe
1	blond	petite	léger	oui	coup de soleil
2	roux	grande	moyen	non	bronzé
3	brun	moyenne	moyen	non	bronzé
4	blond	petite	lourd	oui	coup de soleil

solution :

1. Construire l'arbre de décision correspondant à cette base en utilisant l'algorithme ID3.



3. Donner la précision de l'arbre

Précision = $\frac{1}{4} = 25\%$

Exercice 7 :

Nous considérerons l'ensemble suivant d'exemples caractérisé par les attributs :
Forme, Taille et Couleur.

Forme	Taille	Coleur	Classe
rond	petit	bleu	oui
carré	grand	rouge	non
rond	?	blanc	oui
carré	petit	bleu	oui
rond	grand	bleu	oui
carré	grand	blanc	non
carré	?	blanc	oui
carré	grand	bleu	non
carré	petit	rouge	oui
rond	grand	blanc	oui

1. Remplacer les données manquantes par le mode de l'attribut correspondant.
2. Construire l'arbre de décision correspondant par l'algorithme ID3.

3. Donner le taux de reconnaissance de l'arbre construit sur la table suivante :


Forme	Taille	Coleur	Classe
carré	petit	blanc	non
carré	grand	bleu	oui
rond	petit	rouge	oui
carré	grand	rouge	non

Solution :

1. Remplacement des données manquantes :

Forme	Taille	Coleur	Classe
rond	petit	bleu	oui
carré	grand	rouge	non
rond	grand	blanc	oui
carré	petit	bleu	oui
rond	grand	bleu	oui
carré	grand	blanc	non
carré	grand	blanc	oui
carré	grand	bleu	non
carré	petit	rouge	oui
rond	grand	blanc	oui

2. Arbre de décision



3. Précision = $\frac{2}{4}$ = 50%