

Evaluation de Performance

Dr. Haiahem Rahim

Université Badji Mokhtar-Annaba

haiahem.rahim@gmail.com

December 12, 2022

CHAPITRE 1

Introduction à la modélisation et l'évaluation de performance

Qu'est-ce que l'évaluation des performances

L'évaluation des performances consiste

- à créer un système informatique qui répond au mieux aux exigences de son cahier de charge.
- à quantifier le service rendu par un ordinateur ou un système de communication.
 - connaître le temps de réponse d'un client effectuant une réservation sur Internet
 - comparer la consommation électrique de plusieurs configurations de fermes de serveurs
 - coût d'attente (kérosène consommé par les avions qui attendent pour atterrir)
 - coût associé à la perte de clients impatients qui vont chez les concurrents

- ① **La charge** : La charge caractérise la quantité et la nature des demandes soumises au système. (**l'intensité de travail**).
- ② **Unité de mesure** : Une métrique de performance est une quantité mesurable qui capture précisément ce que nous voulons mesurer (le nombre de tâches accomplies par unité de temps, temps de réponse,
- ③ **Les objectifs** :
L'objectif d'une evaluation des performances peut être
 - soit une comparaison des alternatives de conception (Le système existe déjà), c'est-à-dire la quantification de l'amélioration due à une option de conception,
 - soit le dimensionnement du système (Le système n'existe pas),

On distingue deux grands types d'analyse :

① **L'analyse qualitative :**

définie les propriétés structurelles et comportementales du système, telles que l'absence de blocage, les invariants du système, le comportement fini (exp : exclusion mutuelle).

② **L'analyse quantitative :**

le calcul des mesures que l'on veut effectuer sur un système informatique, permettant de quantifier ses performances : débit, temps de réponse, taux d'utilisation de ses ressources,etc.

Parmi les paramètres de performance les plus fréquents, nous pouvons citer :

- **Le temps de réponse (Le temps de séjour R)**
- **Le débit**
- **Le nombre de clients Q**
- **Taux d'utilisation d'une ressource U**
- **Le taux de perte / rejet**

...

Les étapes d'évaluation de performance

Elle se résume en trois étapes :

- **Etape 1** : Comprendre le fonctionnement du système. Le Substituer par un modèle que l'on pourra résoudre soit par des méthodes analytiques (mathématiques) soit par des simulations.
- **Etape 2** : Elaborer un modèle plus fidèle aux caractéristiques et fonctionnements du système. Appliquer une méthode de résolution ou de simulation (au modèle donné).
L'objectif étant d'obtenir les performances du système (temps d'attente, temps de réponse... etc.)
- **Etape 3** : Evaluer les mesures de performance du système selon le formalisme du modèle. Analyser les résultats obtenus par une méthode quelconque.

Modélisation et performance d'un système

- La modélisation est la substitution d'un système par un modèle.
- Un modèle est l'abstraction formelle d'un système réel.
- En fonction de degré d'abstraction on obtient un modèle plus ou moins fidèle au système modélisé.
 - Un modèle très fidèle a son système réel; va être un modèle très compliqué et difficile à analysé.
 - Un modèle peu fidèle, va rendre l'analyse de modèle simple, mais les résultats obtenus sont moins fiables
- Condition de stabilité
Un système non stable ne peut pas être exploité ; il est alors inutile de déterminer ses mesures de performances.

Un modèle peut être caractérisé par plusieurs critères :

- Statique (indépendant de temps), ou dynamique (dépendant de temps).
- Déterministe (évolution déterminée) ou stochastique (probabiliste).
- Discrets ou continu.

L'évaluation de performances peut se réaliser par deux manières :

- Méthodes analytiques

Elles consistent à réduire le système en un modèle mathématique et à l'analyser numériquement.

Il existe de nombreux outils mathématiques : Les réseaux de pétri, Réseaux de files d'attente, les chaines de Markov, les automates.

- La simulation

Il s'agit d'implémenter un modèle simplifié du système à l'aide d'un programme de simulation adéquat.

C'est une technique largement utilisée pour l'évaluation des performances des systèmes informatiques et réseaux de communications.

Quelques exemples d'application


- Mise en file d'attente et suppression de paquets dans les routeurs
 - Les routeurs sont des périphériques réseau essentiels qui dirigent le flux de données sur un réseau.
 - ils ont une ou plusieurs interfaces d'entrée et de sortie qui reçoivent et transmettent respectivement les paquets.
 - La mémoire du routeur est finie, un routeur peut manquer d'espace pour accueillir les paquets fraîchement arrivés.
 - Cela se produit si le taux d'arrivée des paquets est supérieur au taux auquel les paquets sortent de la mémoire du routeur.

Quelques exemples d'application

- Dans une telle situation, les nouveaux paquets sont ignorés ou les paquets plus anciens sont abandonnés.
- Les routeurs doivent implémenter une discipline de mise en file d'attente qui régit la manière dont les paquets sont mis en mémoire tampon ou abandonnés si nécessaire.
- Pour ce type de problème, on peut, par exemple, s'intéresser au **temps du séjour d'un paquet, temps d'attente moyen / au nombre moyen des paquets mis en file d'attente du routeur**

Quelques exemples d'application

- Serveur Web



Lorsque le cache est plein, la politique de gestion du cache doit décider quel(s) document(s) ôter pour faire de la place à un nouveau document.

LRU, pour "Least Recently Used".

LFU pour "Least Frequently Used" où la page la moins fréquemment référencée est ôtée.

- Pour une politique de gestion de cache donnée on peut, par exemple, essayer d'évaluer le taux de "hits", c'est à dire le pourcentage de documents qui sont dans le cache lorsqu'on les demande.

Rappel des notions probabilistes de base

Notion	Signification	Exemple
Expérience aléatoire	Le résultat dépend du hasard	Lancer un dé
Univers des résultats possible : Ω	L'ensemble de tous les résultats possibles d'une expérience aléatoire.	$\Omega = \{1, 2, 3, 4, 5, 6\}$
Événement	C'est un sous ensemble de l'univers des résultats possibles	A : Obtenir un nombre impair $A = \{1, 3, 5\}$
Variable aléatoire $X : \Omega \rightarrow E$ $\omega \rightarrow X(\omega)$	C'est une fonction qui associe à chaque événement d'une expérience aléatoire un nombre (une valeur)	$X : \Omega \rightarrow \{-1, 1\}$ $\omega \rightarrow \begin{cases} X(\omega) = -1 & \text{si } \omega \in \{1, 2, 3\} \\ X(\omega) = 1 & \text{si } \omega \in \{4, 5, 6\} \end{cases}$

Rappel des notions probabilistes de base

Variable aléatoire discrète (V.A.D)	L'ensemble des états E d'une variable aléatoire est un ensemble fini ou infini dénombrable	$X : \Omega \rightarrow \{-1, 1\}$ $\omega \rightarrow \begin{cases} X(\omega) = -1 & \text{si } \omega \in \{1, 2, 3\} \\ X(\omega) = 1 & \text{si } \omega \in \{4, 5, 6\} \end{cases}$ Est une variable aléatoire discrète
Variable aléatoire continue (V.A.C)	L'ensemble des états E d'une variable aléatoire est un intervalle de nombres réels, non dénombrable.	la fonction Random
Probabilité d'état $P(X=n)$	C'est la probabilité que la V.A.D aura comme résultat n, tel que : $0 \leq P(x_i) \leq 1 \quad \forall x_i \in \Omega$ $\sum_{x_i \in \Omega} P(x_i) = 1$	dans l'exemple précédent $P(X=1)=1/2$ Car: $x = 1 \rightarrow \omega \in \{4, 5, 6\}$ Et dans un dé, la probabilité d'avoir une valeur =1/6, donc $1/6+1/6+1/6=1/2$

Rappel des notions probabilistes de base

Notion	Signification	Exemple
La densité de probabilité	La probabilité qu'une variable aléatoire continue aura comme valeur a, $P(X=a)=0$. car il y a une infinité de valeurs. les probabilité d'une V.A.C sera définie par une fonction de densité sur un intervalle, tel que : $P(a \leq X \leq b) = \int_b^a f(x)dx$ Tel que: $\int_{-\infty}^{+\infty} f(x)dx = 1$	Loi exponentiel de paramètres λ. $f(x) = \begin{cases} \lambda \exp^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{si } x \leq 0 \end{cases}$
La moyenne (l'espérance) d'une loi de probabilité	Elle caractérise la position de l'ensemble des valeurs possibles d'une variable aléatoire. V.A.D : $E[X] = \sum_{x_i \in \Omega} x_i P(x_i)$ V.A.C : $E[X] = \int_{-\infty}^{+\infty} x f(x)dx$	- Loi exponentiel de paramètres λ. Sa moyenne $E[X] = \frac{1}{\lambda}$ - La lois de poisson de paramètres λ, est une loi discrète définie par : $P(X = n) = \frac{\lambda^n}{n!} e^{-\lambda}$ Sa moyenne : $E[X] = \lambda$

Quelques caractéristiques des lois de probabilité :

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \text{ et si } A \cap B = \phi \text{ alors } P(A \cup B) = P(A) + P(B)$$

$$P(A^c) = 1 - P(A)$$

$$P(A \setminus B) = \frac{P(A \cap B)}{P(B)}$$

Si deux évènements sont indépendants alors : $P(A \setminus B) = P(A)$

Si $B_1, B_2, B_3, \dots, B_n$ représente une partition totale de Ω , alors :

$$P(A) = \sum_{k=1}^{+\infty} P(A \setminus B_k) P(B_k)$$

CHAPITRE 2

Modèle d'attente markoviens

- Une chaîne de Markov est un processus de Markov à temps discret, ou à temps continu et à espace d'états qui peut être discret ou continu.
- Un processus de Markov est un **processus stochastique (un phénomène naturel)** possédant la propriété de Markov :

la propriété de Markov :

l'information utile pour la prédiction du futur est entièrement contenue dans l'état présent du processus et n'est pas dépendante des états antérieurs (**le système n'a pas de mémoire**).

- **Un processus stochastique** (X_t) est une famille de variables aléatoires à valeurs dans l'espace des états noté E et indexées par le paramètre de temps t . La valeur X_t est l'état du processus à l'instant t .

Si l'ensemble T est :

- Dénombrable, on parle d'un processus stochastique discret,
- s'il est continu, le processus stochastique est dit continu.

- **Processus Markovien**

C'est un processus stochastique qui satisfait la propriété de perte de mémoire, annoncée comme suit :

$$P(X_{n+1} = j \mid X_n = i_n, X_{n-1} = i_{n-1}, \dots, X_1 = i_1, X_0 = i_0) = P(X_{n+1} = j \mid X_n = i_n)$$

Ceci vaut dire que l'évolution de processus à l'instant $n+1$, ne dépend que de son évolution à l'instant n , et pas de celle de l'historique de processus.

- **Probabilité de transition**

On appelle probabilité de transition, les probabilités de passé de n'importe quel état $i \in E$, à un autre état $j \in E$. Qui vaut dire qu'on doit définir les probabilités $P(X_{n+1} = j | X_n = i) \forall i, j \in E$.

Exemple:

Si on a trois états: i, j, k , et supposant que le processus démarre à l'instant $t=0$ depuis l'état i , donc $P(X_0 = i) = 1$ on doit définir :

à l'instant 1 : $P(X_1 = i \setminus X_0 = i), P(X_1 = j \setminus X_0 = i), P(X_1 = k \setminus X_0 = i)$

à l'instant 2 : $P(X_2 = i \setminus X_1 = i), P(X_2 = j \setminus X_1 = i), P(X_2 = k \setminus X_1 = i)$
 $P(X_2 = i \setminus X_1 = j), P(X_2 = j \setminus X_1 = j), P(X_2 = k \setminus X_1 = j)$
 $P(X_2 = i \setminus X_1 = k), P(X_2 = j \setminus X_1 = k), P(X_2 = k \setminus X_1 = k)$

à l'instant 3 :

Une chaîne de Markov est dite **homogène**, si les probabilités de transition entre états ne dépendent pas du temps.

Ce qui signifie qu'elle ne dépend pas de l'instant dans laquelle la transition se réalise, mais seulement de l'état depuis lequel elle s'est produit.

$$\forall n \in T : P(X_{n+1} = j | X_n = i) = P_{ij}$$

Si la chaîne de Markov est homogène, nous pouvons alors lui associer une matrice de transition entre états (MT).

Une telle matrice est stochastique, ce qui signifie que la somme des valeurs de chaque ligne est égale à 1 :

$$\sum_{j \in E} P_{ij} = 1$$

Chaîne de Markov Discrète (CMTD)

Une chaîne de Markov discrète est complètement définie par :

- Un graphe orienté, dans lequel chaque nœud représente un état de la chaîne.
- Les transitions entre les états
 - Pondérées par les probabilités de transition d'un état de la chaîne à un autre.
 - ou sont représentés par une matrice de transition Q .
- Le vecteur de probabilité d'états initiaux $\pi^{(0)} = (\pi_i^{(0)})$, $i \in E$, qui vaut dire la probabilité d'être dans un état i à l'instant initial 0.

Avec une chaîne de Markov discrète, on s'intéresse à deux types d'analyses:

Une analyse transitoire : elle s'intéresse à prédire l'état du modèle, à un instant n , qui vaut dire calculer le vecteur de probabilité à un instant n .

Une analyse stationnaire : elle s'intéresse à prédire l'état du modèle lorsque il atteint sa stabilité, après un fonctionnement très long ($n \rightarrow +\infty$). (n n'est pas atteinte par tous les modèles).

● Analyse transitoire

On s'intéresse à calculer le vecteur de probabilité d'états à l'instant n ,

$\pi^{(n)} = (\pi_i^{(n)}), i \in E$, tel que $\pi^{(n)} = \{P(X_n = i)\}$, on a:

$$\pi^{(n)} = \pi^{(n-1)} * MT = \dots\dots\dots = \pi^{(0)} * MT^n$$

Tel que:

La probabilité $p_{ij}^{(n)}$ qui représente la valeur qui se situe à la i ème ligne et j ème colonne dans la matrice MT^n , désigne la probabilité d'atteindre l'état j depuis l'état i , après n étapes :

$$p_{ij}^{(n)} = (X_{m+n} = j \setminus X_m = i)$$

Les probabilités de la matrice de transition vérifiées l'équation de Chapman Kolmogorov :

$$p_{ij}^{(n)} = \sum_{k \in E} p_{ik}^{(m)} * p_{kj}^{(n-m)}, \quad 0 < m < n$$

- Analyse stationnaire

On s'intéresse à calculer le vecteur de probabilité π , lorsque $n \rightarrow +\infty$, qui vaut dire:

$$\pi = \lim_{n \rightarrow +\infty} \pi^{(n)}$$

Exemple :

Considérons un système pouvant se trouver à deux états possibles, en un jour n . L'état en marche (M), et l'état en panne (P). Et soit les probabilités suivantes:

- La probabilité d'être en marche et de rester en marche le jour suivant est $\frac{3}{5}$.
- La probabilité d'être en marche et puis de tomber en panne le jour suivant est $\frac{2}{5}$.

- La probabilité d'être en panne et de rester en panne le jour suivant est $\frac{1}{2}$.
- La probabilité d'être en panne et puis d'être en marche le jour suivant est $\frac{1}{2}$.

En supposant que l'état initial est $\pi^{(0)} = (1, 0)$, calculer les probabilités des états $\pi^{(1)} \dots \pi^{(5)}$.

Calculer la probabilité de transition de l'état P en M après 3 étapes.

La propriété de stationnarité n'est pas atteinte par tous les modèles, et donc il faut vérifier à chaque fois, avant de passer à son calcul si elle existe et si elle est unique ?

- Une CMTD irréductible :

Une CMTD est dite irréductible si de n'importe quel état i on peut atteindre tout état j , en un nombre fini d'étapes.

- Une CMTD apériodique :

La périodicité d'un état i , est : $d(i) = PGCD\{k > 1, \text{telque } p_{ii}^{(k)} > 0\}$,
C'est le plus grand commun diviseur des longueurs des circuits allant de i à i .

La période d'une CMTD égale au PGCD de la période de chacun de ses états. Elle est égale au PGCD de la longueur de tous les circuits de la chaîne.

Une CMTD est dite **apériodique** si sa période est égale à un, sinon elle est dite périodique.

Une CMTD ergodique

Une chaîne de Markov à temps discret finie, est ergodique si et seulement si elle est :

- apériodique
- Irréductible

Une CMTD stationnaire

Une chaîne de Markov admet une distribution **stationnaire unique** sur ses états, si elle est **ergodique**.

Ceci vaut dire que le vecteur de probabilité d'états d'une CMTD ergodique se stabilise après l'écoulement d'un temps infini, ce vecteur π est indépendant de la distribution initiale et il se calcule en résolvant le système d'équations suivant :

$$\begin{cases} \pi \cdot Q &= \pi \\ \sum_{i \in E} \pi_i &= 1 \end{cases}$$

Exercise : Soit la matrice de transition d'une CMTD :

$$\begin{pmatrix} 0,1 & 0,5 & 0,4 \\ 0,6 & 0,2 & 0,2 \\ 0,3 & 0,4 & 0,3 \end{pmatrix}$$

- Représenter la matrice de transition sous forme d'un graphe avec 3 états $\{1,2,3\}$
- Est ce que la chaine est ergodique
- Est ce que sa distribution de probabilité est stationnaire ? Si oui calculer son vecteur de probabilité.

Chaine de Markov Continue (CMTC)

Une chaine de Markov continue est une chaine de markov dont l'évolution du temps est continue.

Soit X_t , la variable qui va modéliser l'état du système à l'instant t . Les instants de changement d'états $t_1, t_2, \dots$ sont des points aléatoires dans le temps, pas nécessairement entiers.

Puisque c'est une chaine de Markov, donc elle vérifie la contrainte de perte de mémoire :

$$P(X_{t_{n+1}} = j | X_{t_n} = i_n, X_{t_{n-1}} = i_{n-1}, \dots, X_{t_1} = i_1, X_{t_0} = i_0) = P(X_{t_{n+1}} = j | X_{t_n} = i_n), \forall t_0 < t_1 < \dots < t_{n+1}$$

Les transition entre états se font à des instants quelconque non dénombrable, tandis que l'ensemble d'états E est toujours dénombrable (fini ou infini).

une CMTC est homogène si la probabilité $P(X_{t_{n+1}} = j | X_{t_n} = i_n)$, ne dépend pas des instants t_{n+1} et t_n , mais plutôt de la durée $(t_{n+1} - t_n)$ qui sépare les deux observations.

$$p_{ij}(t) = p_{ij}(s + t, s) = P(X_{s+t} = j | P(X_s = i)) = P(X_t = j | P(X_0 = i)) \quad \forall t \geq 0$$

Une CMTC peut être définie par:

- soit un graphe orienté dont les noeuds représentent les états et les arcs sont pondérés par les taux de transition.
- soit par une matrice Q des taux de transition

Les équations d'états dites aussi les équations de Chapman kolmogorov peuvent d'être calculer ainsi:

soit $\pi(t) = \{\pi_i(t), i \in E\}$, tel que $\pi_i(t) = P(X(t) = i)$

Ces probabilités vérifient l'équation d'états suivante:

$$\frac{d\pi_i(t)}{dt} = \sum_{j \neq i} \lambda_{ji}(t)\pi_j(t) - \sum_{j \neq i} \lambda_{ij}(t)\pi_i(t)$$

Sous forme matricielle ceci va donner :

$$\frac{d\pi(t)}{dt} = \pi(t)Q(t)$$

Tel que $Q(t)$ est la matrice des taux de transition.

Stationnarité d'une CMTC

Une CMTC est stationnaire (ergodique) si elle est finie et irréductible.

Dans ce cas elle accepte une distribution stationnaire unique, obtenue par la résolution de système d'équations :

$$\begin{cases} \pi Q = 0 \\ \sum_{i=1}^n \pi_i = 1 \end{cases}$$

Dans le cas stationnaire, il n'y aura pas de changement d'états ($\frac{d\pi_i(t)}{dt} = 0, \forall i \in E$), par conséquent:

$$\begin{aligned} &\text{le flux entrant} = \text{flux sortant} \\ &\sum_{j \neq i} \lambda_{ji}(t) \pi_j(t) = \sum_{j \neq i} \lambda_{ij}(t) \pi_i(t) \end{aligned}$$

Un processus de naissance et de mort est un processus de Markov à temps continu et à un espace d'états discret. Il est donc caractérisé par deux conditions importantes:

- Perte de mémoire
- les seules transitions possibles, à partir d'un état donné n , sont vers des voisins $n-1$ et $n+1$ ($n \geq 0$).

Processus de naissance

Soit $\{N(t), t \geq 0\}$, est le nombre d'individus dans la population à la date t , et $S = \{0, 1, 2, \dots\}$ est l'espace d'états. Un processus de naissance est caractérisé par l'apparition d'un individu, au sein d'une population, selon une certaine loi.

Il est **homogène**, si la probabilité d'apparition

- d'un individu pendant l'intervalle Δt , sachant qu'il existe déjà n individus au sein de la population est $\lambda_n \Delta t + o(\Delta t)$.
- d'aucun individu est $1 - \lambda_n \Delta t + o(\Delta t)$.
- de deux ou plus est $o(\Delta t)$.

Ici, λ_n représente le taux d'apparition ou le taux de croissance.

Soient $P_n(t) = Pr(N(t) = n)$ les probabilités d'états, ($N(t)$ durant $[0, t]$) ;
 et p_{ij} la probabilité que à l'instant t l'effectif est j sachant qu'il y avait
 déjà i individus dans la population (les probabilités de transitions).

On a que $p_{ij} = 0$ si $j < i$.

Encore, $p_n(t) = p_{0,n(t)} = p_{1,n+1}(t) = \dots$ (le processus est homogène).

Le graphe de transitions est présenté par la figure suivante :




Figure: Graphe de transitions de processus de naissance

La matrice des transitions se présente de la manière suivante :

$$M = \begin{pmatrix} 1 - \lambda_0 \Delta t & \lambda_0 \Delta t & 0 & \dots \\ 0 & 1 - \lambda_1 \Delta t & \lambda_1 \Delta t & 0 \\ 0 & 0 & 1 - \lambda_2 \Delta t & \lambda_2 \Delta t \\ \dots & \dots & \dots & \dots \end{pmatrix}$$

Le régime transitoire est décrit par $P(t + \Delta t) = P(t) \times M$:

$$[p_0(t + \Delta t), p_1(t + \Delta t), \dots, p_n(t + \Delta t), \dots] = [p_0(t), p_1(t), \dots, p_n(t), \dots] \times M,$$

ou bien,

$$\left\{ \begin{array}{l} p_0(t + \Delta t) = p_0(t)(1 - \lambda_0 \Delta t) \\ p_1(t + \Delta t) = p_0(t)\lambda_0 \Delta t + p_1(t)(1 - \lambda_1 \Delta t) \\ \text{-----} \\ p_n(t + \Delta t) = p_{n-1}(t)\lambda_{n-1} \Delta t + p_n(t)(1 - \lambda_n \Delta t) \\ \text{-----} \end{array} \right.$$

A présent, on trouve

$$\left\{ \begin{array}{l} \frac{p_0(t + \Delta t) - p_0(t)}{\Delta t} = -\lambda_0 p_0(t); \\ \text{-----} \\ \frac{p_n(t + \Delta t) - p_n(t)}{\Delta t} = \lambda_{n-1} p_{n-1}(t) - \lambda_n p_n(t), n \geq 1 \end{array} \right.$$

Faisons $\Delta t \rightarrow 0$. Alors, on obtient le systèmes d'équations différentielles (équations du futur) suivant :

$$\left\{ \begin{array}{l} p_0'(t) = -\lambda_0 p_0(t); \\ \text{-----} \\ p_n'(t) = \lambda_{n-1} p_{n-1}(t) - \lambda_n p_n(t), n \geq 1 \end{array} \right.$$

On a que $p_0(0) = 1$ (population est vide) et $p_n(0) = 0 \forall n \geq 1$.
Ici, le processus est en régime transitoire.

Processus de mort

Soit $\{N(t), t \geq 0\}$. L'espace d'états est $S = \{0, 1, 2, \dots\}$. Ce processus est caractérisé par la disparition d'un individu au sein d'une population :

$$\begin{cases} \Pr(N(t + \Delta t) - N(t) = -1 / N(t) = k) = \mu_k \Delta t + o(\Delta t); \\ \Pr(N(t + \Delta t) - N(t) = 0 / N(t) = k) = 1 - \mu_k \Delta t + o(\Delta t); \\ \Pr(N(t + \Delta t) - N(t) = 2 / N(t) = k) = o(\Delta t); \end{cases}$$

μ_k est le taux de décroissance ($\mu_k > 0, k > 0; \mu_0 = 0$).

Le graphe de transitions est donné par la figure suivante:




Figure: Graphe de transitions de processus de mort

Processus de naissance et de mort

Soit $\{N(t), t \geq 0\}$ avec $S = 0, 1, 2, \dots$. Ce processus est homogène dans le temps : les probabilités de transitions $p_{ij} = \Pr(N(t + \Delta t) = j | N(t) = i)$ ne dépend pas de t .

c'est un processus de naissance et de mort si :

$$\left\{ \begin{array}{l} p_{i,i+1}(\Delta t) = \lambda_i \Delta t + o(\Delta t), i \geq 0; \\ p_{i,i-1}(\Delta t) = \mu_i \Delta t + o(\Delta t), i \geq 1; \\ p_{i,i}(\Delta t) = 1 - (\lambda_i + \mu_i) \Delta t + o(\Delta t); i \geq 0 \\ p_{i,j}(\Delta t) = o(\Delta t); |i - j| \geq 2 \end{array} \right.$$

On a également que $\lambda_i > 0, \mu_i > 0, \mu_0 = 0, p_{ij}(0) = \begin{cases} 1 & ; i=j \\ 0 & ; i \neq j \end{cases}$

- Régime transitoire

Soient $p_n(t) = Pr(N(t) = n)$, $n \geq 0$, les probabilités d'état.

Le graphe de transitions est donnée dans la figure suivante :




Figure: Graphe de transitions de processus de naissance et de mort

- La matrice des transitions correspondante est

$$M = \begin{pmatrix} 1 - \lambda_0 \Delta t & \lambda_0 \Delta t & 0 & \dots \\ \mu_1 \Delta t & 1 - (\lambda_1 + \mu_1) \Delta t & \lambda_1 \Delta t & 0 \\ 0 & \mu_2 \Delta t & 1 - (\lambda_2 + \mu_2) \Delta t & \lambda_2 \Delta t \\ \dots & \dots & \dots & \dots \end{pmatrix}$$

En appliquant $P(t + \Delta t) = P(t) * M$, on trouve

$$\begin{cases} p_0(t + \Delta t) = p_0(t)(1 - \lambda_0 \Delta t) + p_1(t)\mu_1 \Delta t \\ p_n(t + \Delta t) = p_{n-1}(t)\lambda_{n-1} \Delta t + p_n(t)[1 - (\lambda_n + \mu_n) \Delta t] + p_{n+1}(t)\mu_{n+1} \Delta t, n \geq 1 \end{cases}$$

On déduit les équations de Kolmogorov

$$\begin{cases} p'_0(t) = -\lambda_0 p_0(t) + \mu_1 p_1(t); \\ p'_n(t) = \lambda_{n-1} p_{n-1}(t) - (\lambda_n + \mu_n) p_n(t) + \mu_{n+1} p_{n+1}(t), n \geq 1 \end{cases}$$

- Régime stationnaire

Soit $p_n = \lim_{t \rightarrow \infty} p_n(t)$, qui est la distribution stationnaire du processus étudié. Ces probabilités satisfont le système d'équations de balance suivant (du système d'équations de kolmogorov en prenant $\lim_{t \rightarrow \infty}$) :

$$\lambda_0 p_0 = \mu_1 p_1 \quad (1)$$

$$p_n(\lambda_n + \mu_n) = \mu_{n+1} p_{n+1} + \lambda_{n-1} p_{n-1}, n \geq 1 \quad (2)$$

avec l'équation de normalisation

$$\sum_{n=0}^{\infty} p_n = 1$$

De l'équation 1, on obtient

$$p_1 = \frac{\lambda_0}{\mu_1} p_0$$

De l'équation 2, on obtient pour n=1

$$p_1(\lambda_1 + \mu_1) = \mu_2 p_2 + \lambda_0 p_0; p_2 = \frac{\lambda_0 \lambda_1}{\mu_1 \mu_2} p_0$$

$$p_n = \frac{\lambda_0 \lambda_1 \dots \lambda_{n-1}}{\mu_1 \mu_2 \dots \mu_n} p_0$$

Pour déduire p_0 , on utilise l'équation de normalisation. On obtient le résultat suivant

$$p_0 = \left[1 + \frac{\lambda_0}{\mu_1} + \frac{\lambda_0 \lambda_1}{\mu_1 \mu_2} + \dots + \frac{\lambda_0 \lambda_1 \dots \lambda_{n-1}}{\mu_1 \mu_2 \dots \mu_n} + \dots \right]^{-1}$$

Par conséquent, pour qu'une distribution stationnaire existe, il faut donc que la somme [] converge. Ceci a toujours lieu si l'espace d'états du processus à l'étude est fini.

La théorie de files d'attente

- Le formalisme de files d'attente est la technique la plus largement utilisée pour l'évaluation de performances des systèmes.
- Elle permet d'abstraire le comportement de ces systèmes de façon assez réaliste.
- L'étude d'un système par la théorie des files d'attente fait appel à la notion de (serveur) de "file d'attente" et de (clients). Cette terminologie s'adapte quel que soit le domaine concerné.

Dans un système d'attente, des clients arrivent de manière aléatoire dans un système d'où ils partiront après avoir reçu un service, dont la durée est elle-même aléatoire.

La figure suivante représente un schéma classique d'un modèle d'attente.




Figure: Schéma d'une file d'attente.

Exemples :

- 1 **les réseaux téléphoniques** : Les clients dans ce cas sont des appels téléphoniques arrivant à un central, et les temps de service sont les durées des communications.
- 2 **Avec l'essor de l'informatique, on a assisté sur l'application des files d'attente dans la gestion des réseaux** : Là les clients sont des programmes à traiter ou des paquets de données à acheminer.

Caractéristiques des files d'attente simples

On peut caractériser les files d'attente par plusieurs critères :

- Le processus d'arrivée des clients.
- Le temps de service.
- La discipline de service.
- La capacité du système.

Notation de Kendall La notation de Kendall résume par des symboles, séparés par des barres obliques les différents paramètres de définition du modèle.

Arrivées / Services / Serveurs / Capacité / Population / Discipline
Ou : A/B/c/m

Cette notation est standard avec :

- A La distribution de probabilité du temps inter-arrivées.
- B La distribution de probabilité du temps de service.
- c Le nombre de serveurs.
- m La capacité du système (taille de la file d'attente).

Processus d'arrivée des clients et temps de service

A et B pourront prendre les valeurs suivantes :

- M : markovien (i.e. exponentiel).
- G : loi générale.
- D : loi déterministe.
- E_k : loi de Erlang .
- H_k ; loi hyperexponentielle.

Si il y a des arrivées groupées on pourra utiliser la notation $A^{[X]}$ où X est la variable aléatoire mesurant le nombre de clients à chaque arrivée.

$\Pr(X = k) = \Pr(k \text{ clients arrivent en même temps})$.

Discipline de la file

C'est l'ordre dans lequel les clients en attente sont traités.

- Par défaut, on considérera la discipline PAPS (premier arrivé premier servi) ou FIFO en anglais (first in first out).
- Dernier arrivé premier servi (ou LIFO : last in first out).
- Aléatoire (ou FIRO : first in random out). Le serveur choisit au hasard parmi les clients présents le prochain qui sera servi.
- HL (Hold On Line) : si un client important arrive, il prend la première place dans la file d'attente.
- PR (Preemption) : si un client important arrive, il est servi directement et le client moins important (en train d'être servi) est remis dans la file.

Notation abrégée

On utilisera la notation abrégée $A/B/c$ quand on considère une file où :

- La capacité du système est infinie.
- La discipline est FIFO.
- Il ya c serveurs dans le système.

Exemple : La notation $M/D/1/4$ définit un système d'attente comprenant une station service et pour lequel la longueur maximale de la file d'attente vaut 3. Le processus d'arrivée est un processus de Poisson et la durée du service est constante (Déterministe).

Exercice : Expliquer les notations suivantes : $M/M/2/5$, $M/G/5/\infty$ et $M/E1/\infty/\infty$.

Analyse mathématique et mesures de performance

L'étude mathématique d'un système de files d'attente se fait par l'introduction d'un processus stochastique défini de façon appropriée $\{N(t), t \geq 0\}$. En général, on s'intéresse au nombre $N(t)$ de clients se trouvant dans le système à l'instant $t \geq 0$, en fonction des quantités qui déterminent la structure du système.

On cherche à calculer :

- 1 **Les probabilités d'état** $p_n(t) = Pr(N(t) = n)$ qui définissent le régime transitoire du processus $N(t), t \geq 0$, les probabilités p_n doivent évidemment dépendre de l'état initial ou la distribution initiale du processus,
- 2 **Les probabilités d'état** qui définissent le régime stationnaire du processus en question, sont défini par

$$p_n = \lim_{t \rightarrow \infty} p_n(t)$$

La distribution stationnaire du processus stochastique introduit permet d'obtenir les caractéristiques d'exploitation du système, telles que :

- Le temps d'attente d'un client,
- Le temps de séjour d'un client dans le système,
- Le taux d'occupation des dispositifs de service,
- La durée de la période d'activité,

et également les mesures de performance :

- Le nombre moyen de clients dans le système $\bar{n}$;
- Le nombre moyen de clients dans la file d'attente $\bar{n}_f$;
- Le temps moyen d'attente d'un client $\bar{W}$;
- Le temps moyen de séjour d'un client dans le système $\bar{W}_s$.

Et on a encore les relations suivantes:

Formules de Little

$$\bar{n} = \lambda \bar{W}_s; \bar{n}_f = \lambda \bar{W}; \bar{W}_s = \bar{W} + \frac{1}{\mu}; \bar{W} = \frac{\bar{n}_f}{\lambda}; \bar{n} = \bar{n}_f + \frac{\lambda}{\mu}$$

où λ est le taux d'entrée des clients dans le système, $\frac{1}{\mu}$ est la durée moyenne de service ($\mu > 0$).

Une autre mesure importante d'un système de files d'attente, celle qui mesure le degré de saturation du système, est **l'intensité du trafic** ρ . Elle est définie par :

$$\rho = \frac{\lambda}{\mu}$$

Système de files d'attente markoviens

- Les modèles Markoviens sont des systèmes où les temps entre deux arrivées successives et les durées de service sont des variables aléatoires indépendantes et exponentiellement distribuées.
- On s'intéresse au nombre $N(t)$ de clients se trouvant dans le système à l'instant t . On introduit donc le processus stochastique:

$$\{N(t), t \geq 0\}$$

- Les modèles Markoviens ont en commun que le processus précédent qui constitue une chaîne de Markov à temps continu homogène,
* **ce qui signifie que le comportement futur ne dépend que de l'état présent et non pas de l'évolution dans le passé.**

- Supposons que la discipline d'attente est FIFO, alors

$$\{N(t), t \geq 0\}$$

est un processus de naissance et de mort, qui est une chaîne de Markov à temps continu et à états discrets.

Système de files d'attente M/M/1

Description du modèle :

- Les clients arrivent vers le système selon un processus de Poisson de taux λ (nombre moyen de clients arrivant pendant une unité de temps). c'est-à-dire l'intervalle de temps entre deux arrivées successives suit une loi exponentielle de même paramètre $\lambda > 0$.
- Le service est assuré par un seul serveur. A l'arrivée d'un client, si le serveur est libre, il est immédiatement pris en charge. Dans le cas contraire, le client en question est placé en attente.
- La capacité d'attente est illimitée (le nombre de positions est infini et aucune autre restriction n'est imposée).

- La discipline d'attente est FIFO. Les durées de service suivent une loi exponentielle de paramètre $\mu > 0$. Par conséquent, le taux de service est μ (nombre moyen de clients servis pendant une unité de temps), et le temps moyen de service d'un client est $\frac{1}{\mu}$.
- Les variables aléatoires représentant les durées entre deux arrivées consécutives et les durées de service sont mutuellement indépendantes.

L'état du système à la date t peut être décrit par le processus stochastique

$$\{N(t), t \geq 0\}$$

on a pour un petit intervalle du temps Δt les probabilités suivantes :

$$\left\{ \begin{array}{l} \Pr(\text{exactement une arrivée pendant } \Delta t) = \lambda \Delta t + o(\Delta t) \\ \Pr(\text{aucune arrivée pendant } \Delta t) = 1 - \lambda \Delta t + o(\Delta t) \\ \Pr(\text{deux arrivées ou plus pendant } \Delta t) = o(\Delta t) \\ \Pr(\text{exactement un départ pendant } \Delta t / N(t) > 0) = \mu \Delta t + o(\Delta t) \\ \Pr(\text{aucun départ pendant } \Delta t / N(t) > 0) = 1 - \mu \Delta t + o(\Delta t) \\ \Pr(\text{deux départs ou plus pendant } \Delta t) = o(\Delta t) \end{array} \right.$$

Soient $p_{ij}(\Delta t) = \Pr(N(t + \Delta t) = j / N(t) = i)$, $i = 0, 1, 2, \dots$. Ces probabilités de transition ne dépendent ni de temps ni de l'état dans lequel le système se trouve.

Régime transitoire




Figure: Graphe de transitions de la file M/M/1

Soit $P_n(t) = Pr(N(t) = n)$, $n = 0, 1, 2, \dots$ et le graphe des transitions est donné dans la figure précédente. A partir du graphe des transitions, on obtient :

$$\begin{cases} p_0(t + \Delta t) = \mu \Delta t p_1(t) + [1 - \lambda \Delta t] p_0(t) \\ p_n(t + \Delta t) = \mu \Delta t p_{n+1}(t) + \lambda \Delta t p_{n-1}(t) + [1 - (\lambda + \mu) \Delta t] p_n(t), n \geq 1 \end{cases}$$

Puis, les équations de Kolmogorov :

$$\begin{cases} p'_0(t) = -\lambda p_0(t) + \mu p_1(t) \\ p'_n(t) = -(\lambda + \mu) p_n(t) + \lambda p_{n-1}(t) + \mu p_{n+1}(t), n \geq 1 \end{cases}$$

Régime stationnaire

Comme il est démontré que $\lim_{t \rightarrow \infty} p_n(t) = p_n, n \geq 0$, existent et sont indépendantes de l'état initial du processus $N(t)$; et

$$\lim_{t \rightarrow \infty} p'_n(t) = 0, n \geq 0$$

à partir des équations de kolmogorov, on obtient le système d'équations de balance suivant :

$$\begin{cases} \mu p_1 = \lambda p_0 \\ \lambda p_{n-1} + \mu p_{n+1} = (\lambda + \mu) p_n, n \geq 1 \end{cases}$$

La résolution de ce système s'effectue de la manière suivante :

$$\left\{ \begin{array}{l} p_1 = \frac{\lambda}{\mu} p_0 \\ \text{pour } n = 1, \lambda p_0 + \mu p_2 = (\lambda + \mu) p_1, p_2 = \left(\frac{\lambda}{\mu}\right)^2 p_0 \\ \text{pour } n > 1, p_n = \left(\frac{\lambda}{\mu}\right)^n p_0 \end{array} \right.$$

Pour trouver la probabilité p_0 , on utilise l'équation de normalisation. En effet,

$$p_0 + \frac{\lambda}{\mu} p_0 + \left(\frac{\lambda}{\mu}\right)^2 p_0 + \dots = 1$$

$$p_0 = \frac{1}{1 + \frac{\lambda}{\mu} + \left(\frac{\lambda}{\mu}\right)^2 + \dots}$$

où $1 + \frac{\lambda}{\mu} + (\frac{\lambda}{\mu})^2 + \dots$ est une **progression géométrique** de raison $\frac{\lambda}{\mu}$. Elle est convergente si $\frac{\lambda}{\mu} < 1$, et sa solution est égale à $\frac{1}{1 - \frac{\lambda}{\mu}}$.

Par conséquent, $p_0 = 1 - \frac{\lambda}{\mu}$

$$\text{D'où, } p_n = (1 - \frac{\lambda}{\mu})(\frac{\lambda}{\mu})^n$$

$\rho = \frac{\lambda}{\mu}$ est l'intensité du trafic. $\rho = \frac{\lambda}{\mu} < 1$ est la condition d'existence du régime stationnaire.

Encore, $p_n = (1 - \rho)\rho^n, n \geq 0$ est la distribution stationnaire du nombre de clients dans le système M/M/1.

Caractéristiques du système M/M/1 (Mesures de performance)

Soit $N = \lim_{t \rightarrow \infty} N(t)$

Le nombre moyen de clients dans le système

$$\bar{n} = E[N] = \sum_{n=0}^{\infty} n p_n = (1-\rho) \sum_{n=0}^{\infty} n \rho^n = (1-\rho) \rho [1 + 2\rho + 3\rho^2 + \dots] = \frac{\rho}{1-\rho} = \frac{\lambda}{\mu - \lambda}$$

L'expression entre les crochets est une dérivée de $B = \rho + \rho^2 + \rho^3 + \dots$. En effet,

$$B = \rho[1 + \rho + \rho^2 + \dots] = \frac{\rho}{1-\rho} \text{ et } B' = \frac{1}{(1-\rho)^2}$$

Le nombre moyen de clients dans la file d'attente

Soit $N_f = \lim_{t \rightarrow \infty} N_f(t)$ où $N_f(t)$ est le nombre de clients dans la file d'attente à la date t . La variable N_f est définie de la manière suivante :

$$N_f = \begin{cases} 0 & \text{si } N = 0 \\ N - 1 & \text{si } N \geq 1 \end{cases}$$

$$\bar{n}_f = \sum_{n=1}^{\infty} (n-1)p_n = \frac{\lambda^2}{\mu(\mu-\lambda)} \text{ ou bien } \bar{n}_f = \bar{n} - \rho$$

- Le temps moyen d'attente d'un client, Le temps moyen de séjour d'un client dans le système

Le temps moyen d'attente $\overline{W}$ et le temps moyen de séjour $\overline{W}_s$ peuvent être calculés à l'aide de formule de Little, en effet,

$$\overline{W} = \frac{\overline{n}_f}{\lambda} = \frac{\lambda}{\mu(\mu-\lambda)}$$
$$\overline{W}_s = \frac{\overline{n}}{\lambda} = \frac{1}{\mu-\lambda}$$

Système de files d'attente M/M/c

- Les clients arrivent vers le système selon un processus de Poisson de taux $\lambda \geq 0$.

Le service est assuré par $c > 1$ serveurs montés en parallèle. Comme le montre la figure ci-après.




Figure: Modèle d'attente M/M/c

- A l'arrivée d'un client, si l'un des serveurs est libre, le client commence immédiatement son service. Dans le cas contraire (tous les serveurs sont occupés par le service), le client prend place dans la file d'attente, commune pour tous les serveurs.
- La capacité d'attente est illimitée (le nombre de positions d'attente est infini). Lorsqu'un serveur se libère, le client en tête de la file d'attente occupe le serveur libéré. Par conséquent, la discipline d'attente est FIFO.
- Les temps de service sont exponentiellement distribués de moyenne finie $\frac{1}{\mu}$. Les durées entre deux arrivées consécutives et les durées de service sont mutuellement indépendantes.

Analyse du modèle

L'état du système à la date t peut être décrit à l'aide du processus stochastique $N(t)$, dont l'espace des états est $S = \{0, 1, 2, \dots\}$.

Ce dernier est un processus de naissance et de mort dont les taux de transition sont :

$$\begin{aligned}\lambda_n &= \lambda, n \geq 0 \\ \mu_n &= \min\{n, c\}\mu, n \geq 1\end{aligned}$$

Régime transitoire

Soit $p_n(t) = Pr(N(t) = n)$, $n = 0, 1, 2, \dots$. Le graphe des transitions est représenté dans la figure ci-après.




Figure: Graphe de transitions de la file M/M/c

A partir du graphe des transitions, on obtient Le système d'équations suivant :

$$p_0(t + \Delta t) = (1 - \lambda \Delta t) p_0(t) + \mu \Delta t p_1(t)$$

$$p_n(t + \Delta t) = \lambda \Delta t p_{n-1}(t) + [1 - (\lambda + n\mu) \Delta t] p_n(t) + (n + 1) \mu \Delta t p_{n+1}(n), 1 \leq n < c$$

$$p_n(t + \Delta t) = \lambda \Delta t p_{n-1}(t) + [1 - (\lambda + c\mu) \Delta t] p_n(t) + c\mu \Delta t p_{n+1}(n), n \geq c$$

Le système d'équations de Kolmogorov se présente de la manière suivante :

$$p'_0(t) = -\lambda p_0(t) + \mu p_1(t)$$

$$p'_n(t) = \lambda p_{n-1}(t) - (\lambda + n\mu) p_n(t) + (n + 1) \mu p_{n+1}(n), 1 \leq n < c$$

$$p'_n(t) = \lambda p_{n-1}(t) - (\lambda + c\mu) p_n(t) + c\mu p_{n+1}(n), n \geq c$$

Régime stationnaire

Soit $p_n = \lim_{t \rightarrow \infty} p_n(t)$, $n \geq 0$. Cette distribution stationnaire satisfait les équations de balance :

$$0 = -\lambda p_0 + \mu p_1$$

$$0 = \lambda p_{n-1} - (\lambda + n\mu)p_n + (n+1)\mu p_{n+1}, 1 \leq n < c$$

$$0 = \lambda p_{n-1} - (\lambda + c\mu)p_n + c\mu p_{n+1}, n \geq c$$

La résolution du système d'équations ci-dessus nous donne :

$$p_n = \frac{1}{n!} \left(\frac{\lambda}{\mu} \right)^n p_0, 1 \leq n < c$$

$$p_n = \frac{1}{c!} \frac{1}{c^{n-c}} \left(\frac{\lambda}{\mu} \right)^n p_0, n \geq c$$

On remarque que pour $n = c$, les deux formules donnent la même valeur.

Pour calculer la probabilité pour que le système est vide p_0 , on applique l'équation de normalisation $\sum_{n=0}^{\infty} p_n = 1$. En effet,

$$p_0 = \left[\sum_{n=0}^{c-1} \frac{1}{n!} \left(\frac{\lambda}{\mu} \right)^n + \sum_{k=0}^{\infty} \frac{1}{c! c^k} \left(\frac{\lambda}{\mu} \right)^{c+k} \right]^{-1}$$

La deuxième somme peut être réécrite de la manière suivante :

$$\frac{1}{c!} \left(\frac{\lambda}{\mu} \right)^c \left[1 + \frac{\lambda}{c\mu} + \left(\frac{\lambda}{c\mu} \right)^2 + \left(\frac{\lambda}{c\mu} \right)^3 + \dots \right]$$

La somme [...] possède une limite égale à $\frac{1}{1-\frac{\lambda}{c\mu}}$ si $\frac{\lambda}{c\mu} < 1$. Par conséquent, le système considéré est en régime stationnaire si $\rho = \frac{\lambda}{c\mu} < 1$, ρ est **l'intensité globale du trafic**. d'où :

$$p_0 = \left[\sum_{n=0}^{c-1} \frac{1}{n!} \left(\frac{\lambda}{\mu} \right)^n + \frac{\left(\frac{\lambda}{\mu} \right)^c}{c! \left(1 - \frac{\lambda}{c\mu} \right)} \right]^{-1}$$

Mesures de performance

- Le nombre moyen de clients dans le système

$$\bar{n} = \sum_{n=0}^{\infty} n p_n$$

$$\bar{n} = \sum_{n=1}^{c-1} \frac{n(\frac{\lambda}{\mu})^n}{n!} p_0 + \sum_{n=c}^{\infty} \frac{n(\frac{\lambda}{\mu})^n}{c! c^{n-c}} p_0$$

$$\bar{n} = \frac{\lambda}{\mu} + \frac{(\frac{\lambda}{\mu})^{c+1}}{cc!(1-\frac{\lambda}{c\mu})^2} p_0$$

- Le nombre moyen de clients dans la file d'attente

$$\bar{n}_f = \sum_{k=0}^{\infty} k p_{c+k}$$

$$\bar{n}_f = \frac{(\frac{\lambda}{\mu})^c}{c!} \sum_{k=0}^{\infty} k (\frac{\lambda}{c\mu})^k p_0$$

$$\bar{n}_f = \frac{(\frac{\lambda}{\mu})^{c+1}}{cc!(1-\frac{\lambda}{c\mu})^2} p_0$$

Le temps moyen de séjour d'un client dans le système

$$\overline{W}_s = \frac{\bar{n}}{\lambda}$$

$$\overline{W}_s = \frac{1}{\mu} + \frac{\left(\frac{\lambda}{\mu}\right)^c}{c\mu c! \left(1 - \frac{\lambda}{c\mu}\right)^2} p_0$$

Le temps moyen d'attente d'un client

$$\overline{W} = \frac{\bar{n}_f}{\lambda}$$

$$\overline{W} = \frac{c\mu \left(\frac{\lambda}{\mu}\right)^c}{c! (c\mu - \lambda)^2} p_0$$

Chapitre 3

Systèmes particuliers de files d'attente (Modèles Markoviens)

Il existe de nombreux modèles d'attente de type markovien pour lesquels le processus stochastique $N(t)$ possède une structure complexe :

- les modèles où les arrivées (ou le service) se font par groupe.
- les modèles avec classes des clients,
- les modèles des files d'attente avec rappel. . . .

Le processus $N(t)$, associé à ces modèles n'est plus de naissance et de mort parce que les transitions à partir d'un état donné peuvent se produire à n'importe quel autre état.

Système de files d'attente $M^X/M/1$

Description du modèle

- Les clients arrivent dans le système par groupe selon un processus de Poisson ($\lambda > 0$).
- Le nombre de clients par groupe est une variable aléatoire X strictement positive : $Pr(X(t) = x) = c_x(t)$.
- Le service est assuré par un seul serveur. Les durées de service suivent une loi commune, exponentielle en occurrence de moyenne finie $\frac{1}{\mu}$.

- A l'arrivée d'un groupe, si le serveur est libre, le premier client du groupe en question est immédiatement pris en charge et les autres clients sont placés en attente (la capacité d'attente est illimitée). Dans le cas contraire, tous les clients du groupe rejoignent la file d'attente.
- La discipline est FIFO.
- Nous supposons que toutes les variables introduites (la durée entre deux arrivées consécutives, la durée de service, la longueur du groupe) sont mutuellement indépendantes.

Analyse du modèle

L'état du système à la date t peut être décrit par le processus stochastique $N(t), t \geq 0$, où $N(t)$ est le nombre de clients dans le système à l'instant t .

L'espace des états est $S = 0, 1, 2, \dots$

Régime transitoire

Soient $p_n(t) = \Pr(N(t) = n)$, $n \geq 0$.

Le graphe des transitions est donné par ...

Système d'équations des probabilités d'état à partir du graphe . En effet,

$$p_0(t + \Delta t) = p_0(t)(1 - \lambda \Delta t) + \mu \Delta t p_1(t);$$

$$p_1(t + \Delta t) = \lambda \Delta t c_1(t) p_0(t) + [1 - (\lambda + \mu) \Delta t] p_1(t) + \mu \Delta t p_2(t);$$

$$p_2(t + \Delta t) = \lambda \Delta t c_1(t) p_1(t) + \lambda \Delta t c_2(t) p_0(t) + [1 - (\lambda + \mu) \Delta t] p_2(t) + \mu \Delta t p_3(t);$$

.....

$$p_n(t + \Delta t) = \lambda \Delta t \sum_{k=1}^n c_k(t) p_{n-k}(t) + [1 - (\lambda + \mu) \Delta t] p_n(t) + \mu \Delta t p_{n+1}(t); n > 2.$$

- Alors le système d'équations de Kolmogorov est :

$$p_0'(t) = -\lambda p_0(t) + \mu p_1(t);$$

$$p_n'(t) = \lambda \sum_{k=1}^n c_k(t) p_{n-k}(t) - (\lambda + \mu) p_n(t) + \mu p_{n+1}(t); n \geq 1.$$

Régime stationnaire

Chapitre 4

Modèle semi-Markoviens

Système de files d'attente M/G/1

Description du modèle

- Les clients arrivent dans le système selon un processus de Poisson de taux $\lambda > 0$. De ce fait, le temps entre deux arrivées successives suit une loi exponentielle de moyenne $\frac{1}{\lambda}$.
- Le service est assuré par un seul serveur. A l'arrivée d'un client, si le serveur est libre, le client sera pris en charge immédiatement. Dans le cas contraire, il rejoint la file d'attente (de capacité illimitée et discipline FIFO).

- les durées de service Se sont des variables aléatoires indépendantes et identiquement distribuées de loi générale dont la fonction de répartition $B(x)$ et la transformée de Laplace-Stieltjes $\hat{B}(s)$.
- $E[Se] = \frac{1}{\mu}$

Analyse du modèle

Pour décrire l'état d'un système de type M/G/1 à la date t , il faut connaître non seulement le nombre de clients qui se trouvent dans le système à la date t , mais également le temps de service déjà écoulé $R(t)$ du client qui est en train d'être servi.

- On peut alors montrer que le processus bidimensionnel $\{N(t), R(t), t \geq 0\}$ est à nouveau du type markovien. Cependant, le calcul de son régime transitoire ferait **intervenir des équations aux dérivées partielles**.
- Par conséquent, on choisit une autre méthode qui ramène l'étude du processus non markovien $\{N(t), t \geq 0\}$ à celle d'une chaîne de Markov à temps discret associée au processus considéré dont elle permet de calculer le régime stationnaire.
- Soit le processus $\{N(t), t \geq 0\}$ qui n'est pas un processus de Markov. Pour le rendre markovien, on utiliserons la méthode de la **chaîne de Markov induite**.

A cet effet, on considère $N(t)$ aux instants $\xi_1, \xi_2, \dots, \xi_n, \dots$ où les clients terminent leur service et quittent le système. On définit ainsi un processus stochastique à temps discret.

$$\{N_n = N(\xi_n), n \geq 1\}$$

(Nombre de clients restants dans le système immédiatement après le départ du n ème client à l'instant ξ_n)

Pour vérifier que cette suite de variables aléatoires est une chaîne de Markov à temps discret, on considère le nombre A_n de clients qui entrent dans le système pendant que le n 'ème client est servi.

Les variables A_n sont indépendantes entre elles, leur distribution commune est

$$\Pr(A_n = k) = a_k = \int_0^{\infty} \exp(-\lambda t) \frac{(\lambda t)^k}{k!} dB(t), \text{ où } a_k > 0 \text{ et } k > 0.$$

Alors :

$$N_{n+1} = \begin{cases} N_n - 1 + A_{n+1} & \text{si } N_n \geq 1 \\ A_{n+1} & \text{si } N_n = 0 \end{cases} ; n \geq 1$$

L'équation fondamentale de la chaîne vaut donc

$$N_{n+1} = N_n - \sigma_n + A_{n+1}$$

ou

$$\delta_n = \begin{cases} 1 & \text{si } N_n > 0 \\ 0 & \text{si } N_n = 0 \end{cases} , n \geq 1$$

N_{n+1} ne dépend que de N_n et de A_{n+1} et non pas des valeurs prises par $N_{n-1}, N_{n-2}, N_{n-3}, \dots$

La suite $\{N_n, n \geq 1\}$ est une chaîne de Markov induite du processus $\{N(t), t \geq 0\}$. Ses probabilités de transition $p_{ij} = Pr(N_{n+1} = j / N_n = i)$ se calculent par

$$\begin{cases} p_{0j} = a_j \text{ si } j \geq 0 \\ p_{ij} = a_{j-i+1} \text{ si } 1 \leq i \leq j+1 \\ p_{ij} = 0 \text{ ailleurs} \end{cases}$$

$$M = \begin{pmatrix} p_{00} & p_{01} & p_{02} & p_{03} & \cdots & \cdots \\ p_{10} & p_{11} & p_{12} & p_{13} & \cdots & \cdots \\ p_{20} & p_{21} & p_{22} & p_{23} & \cdots & \cdots \\ p_{30} & p_{31} & p_{32} & p_{33} & \cdots & \cdots \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \end{pmatrix} = \begin{pmatrix} a_0 & a_1 & a_2 & a_3 & \cdots & \cdots \\ a_0 & a_1 & a_2 & a_3 & \cdots & \cdots \\ 0 & a_0 & a_1 & a_2 & \cdots & \cdots \\ 0 & 0 & a_0 & a_1 & \cdots & \cdots \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \end{pmatrix}.$$

Vu qu'on peut passer de chaque état vers n'importe quel autre état, il s'agit d'une chaîne de Markov irréductible. De plus, la matrice n'est pas décomposable (est apériodique). **La chaîne est donc ergodique.**

La distribution stationnaire de la chaîne existe si $\rho = \frac{\lambda}{\mu} < 1$

Preuve 2

Supposons que $\rho < 1$. Le système se trouve dans un régime stationnaire.

Soit $(\pi_0, \pi_1, \pi_2, \dots)$ la distribution stationnaire de la chaîne de Markov induite ($\pi_j = \lim_{n \rightarrow \infty} Pr(N(\xi_n) = j)$).

Par conséquent, $(\pi_0, \pi_1, \pi_2, \dots) = (\pi_0, \pi_1, \pi_2, \dots) \cdot M$,

Le résultat final est **la première équation de Pollaczek-Khintchine** pour le nombre de clients dans le système :

$$\Pi(z) = \frac{(1-\rho)A(z)(z-1)}{z-A(z)} = \frac{(1-\rho)\tilde{B}(\lambda-\lambda z)(z-1)}{z-\tilde{B}(\lambda-\lambda z)}$$

Mesures de performance

- En général, on admet que la population des clients est homogène, c'est-à-dire que les durées de service des clients sont identiquement distribuées selon une loi de probabilité commune.
- Dans les cas plus complexes où les clients sont divisés en classes, chaque classe peut être identifiée par sa propre distribution du temps de service (population hétérogène).
- De plus, il y a des systèmes où certains clients jouissent d'une priorité de service. La priorité peut être absolue ou relative.

- Par priorité absolue, on entend qu'un client moins prioritaire est remis en tête de file d'attente lorsqu'un client plus prioritaire se présente devant la file d'attente. Ce dernier venu commence son service immédiatement.
- Si la priorité est relative, un nouveau client plus prioritaire attend la fin du service avant de pouvoir commencer le sien.
- Dans le cas de priorité absolue, deux nouvelles possibilités se présentent : soit le client suspendu reprend son service là où il a été interrompu, soit il le reprend depuis le début.

Système de files d'attente M/M/1 avec différentes classes de clients et priorité absolue

Description du modèle

- Considérons un système de files d'attente de type M/M/1.
- Cependant supposons qu'il y a deux classes de clients qui arrivent toujours selon un processus de Poisson ($\lambda > 0$) :
- la proportion des clients de la première classe (clients plus prioritaires) est α , la proportion des clients de la deuxième classe (clients moins prioritaires) est alors $(1 - \alpha)$, (on a $\lambda = \lambda\alpha + \lambda(1 - \alpha) = \lambda_1 + \lambda_2$).

- Les durées de service des clients de la première classe suivent une loi exponentielle de paramètre μ_1 , tandis que celles des clients de la deuxième classe sont réparties selon une loi exponentielle de paramètre μ_2 .
- La priorité est absolue. Par conséquent, les clients de la première classe ne sont pas perturbés par les clients de la deuxième classe.
- Encore, pour les clients de la deuxième classe, vu que la distribution du temps de service est exponentielle (sans mémoire), reprendre le service là où il a été interrompu est équivalent à recommencer depuis le début.

Analyse du modèle Le processus stochastique associé est $N_1(t), N_2(t), t \geq 0$, où $N_1(t)$ est le nombre de clients de la première classe et $N_2(t)$ est le nombre de clients de la deuxième classe dans le système à la date t .

Son espace des états est $S = (n_1, n_2), n_1 \in N, n_2 \in N$.

Le graphe des transitions est donné par la figure

En régime stationnaire:

où $p_{n_1}, p_{n_2} = \lim Pr(N_1(t) = n_1, N_2(t) = n_2), n_1, n_2 \geq 0$.

Nous allons décrire les calculs au lieu de les effectuer. En effet, ils sont longs et fastidieux. Il faut calculer la fonction génératrice :

$$F(x, y) = \sum_{n_1=0}^{\infty} \sum_{n_2=0}^{\infty} p_{n_1, n_2} x^{n_1} y^{n_2}.$$

A partir du système d'équations de balance, on trouve

$$F(x, y) = \left(\frac{1 - \rho_1 - \rho_2}{1 - \eta - y\rho_2} \right) \left(\frac{1 - \eta}{1 - \eta x} \right)$$

où

$$\rho_1 = \frac{\lambda_1}{\mu_1}, \rho_2 = \frac{\lambda_2}{\mu_2} \text{ et}$$

$$\eta = \frac{1}{2\mu_1} \left[\mu_1 + \lambda_1 + \lambda_2(1 - y) - \sqrt{[\mu_1 + \lambda_1 + \lambda_2(1 - y)]^2 - 4\lambda_1\mu_1} \right]$$

De la fonction génératrice, on déduit :

$$\begin{aligned}\bar{n}_1 &= \frac{\partial F(x,y)}{\partial x} \Big|_{x=y=1} = \frac{\rho_1}{1-\rho_1} \\ \bar{n}_2 &= \frac{\partial F(x,y)}{\partial y} \Big|_{x=y=1} = \frac{\rho_2 + E[n_1]\rho_2}{1-\rho_1-\rho_2}\end{aligned}$$

La distribution stationnaire s'obtient également à partir de la fonction génératrice

$$p_{n_1, n_2} = \frac{1}{n_1! n_2!} \left[\frac{\partial^{n_1+n_2} F(x,y)}{(\partial x)^{n_1} (\partial y)^{n_2}} \right]_{x=y=0}$$

en particulier, $p_{0,0} = 1 - \rho_1 - \rho_2$. Pour que la distribution stationnaire existe, $p_{0,0} > 0 : \rho_1 + \rho_2 < 1$.

